

ОТЧЁТ ПО ЭТАПУ 1

Обучение модели слабых технологических сигналов

Данные из открытых источников. Логистическая регрессия. Проверка на шести темах.

Выборка: 223 строки. Требование: четыре метрики от 75%.

Все четыре метрики выше 75%.

29 сентября 2026

Как считали

Текст объяснений из таблицы не использовали как признак

01. Разметка

100 слабых сигналов из таблицы и 123 негативных примера.

02. Сбор

OpenAlex, Google News, GitHub и Википедия.
Дата признаков: 28.09.2026.

03. Признаки

16 числовых признаков: рост, объём, раунды, код, зрелость и состав источников.

04. Модель

Стандартизация и логистическая регрессия.
Для каждого признака виден его вклад.

Ошибки источников

Число ошибок по каждому источнику на 223 строки

OpenAlex	0 / 223	0,0%
Google News	0 / 223	0,0%
GitHub	0 / 223	0,0%
Википедия	0 / 223	0,0%

Условие: отказов каждого источника не более чем в 15% строк.

В обоих дополнительных наборах по 24 строки ошибок тоже нет.

Результаты проверки

Каждая метрика в строке «Валидация по Т3» должна быть от 75%

Метрика	5 фолдов × 3 повтора	Новая тема (LOTO)
Accuracy	80,4%	78,9%
Precision	77,0%	76,2%
Recall	80,3%	77,0%
F1	78,6%	76,6%

При случайном разбиении похожие технологии могут попасть и в обучение, и в проверку. В LOTO модель проверяют на теме, которой не было в обучении.

Веса признаков

Вес после стандартизации

Возраст статьи Википедии

-0,063

Новости о раундах

+0,162

Насыщенный поток новостей

-0,299

Рост публикаций

+0,418

Объём публикаций

-0,244

Рост новостей

+0,244

Доля массовых СМИ

-0,001

Всплеск новостей

+0,040

Нужный знак имеют 8 из 8 весов.

Знаки заданы при обучении. Вес СМИ $-0,001$ почти не влияет на решение.

Что проверяли

Четыре запуска. Полная запись: docs/experiment_log.md

1. Базовая модель: $C=1$, порог 0,50. Accuracy 78,0%, Precision 71,8%, Recall 84,0%, F1 77,4%. Ошибок источников нет. Precision ниже 75%.

2. Порог 0,64 при $C=1$. Accuracy 78,6%, Precision 75,7%, Recall 77,0%, F1 76,4%. Требование выполнено, но в LOTO Recall 70,0%.

3. $C=0,05$ и порог 0,60. Accuracy 80,7%, Precision 77,1%, Recall 81,0%, F1 79,0%. LOTO: 79,8%, 76,7%, 79,0%, 77,8%. Вес массовых СМИ +0,111.

4. Ограничены знаки восьми весов. $C=0,05$, порог 0,60. Accuracy 80,4%, Precision 77,0%, Recall 80,3%, F1 78,6%. LOTO: 78,9%, 76,2%, 77,0%, 76,6%. Вес СМИ -0,001.

Что получилось

Четыре метрики $\geq 75\%$

ВЫПОЛНЕНО

Ошибки каждого источника $\leq 15\%$

ВЫПОЛНЕНО

Знаки весов по методике

ВЫПОЛНЕНО

Оценка сделана на 100 положительных примерах из таблицы и 123 подготовленных негативах. При других поисковых фразах решение менялось 14 из 24 для alt1, 5 из 24 для alt2. Качество поиска кандидатов здесь не проверялось.

Подробные цифры: [docs/metrics_detector.md](#) и [docs/experiments.md](#)